



**Universidad
Europea** VALENCIA

GRADO EN CIENCIA DE DATOS

Detección de retinopatía diabética en imágenes de fondo de ojo mediante redes neuronales convolucionales y técnicas de transfer learning

Presentado por:

ELENA SANJUAN MUÑOZ

Dirigido por:

ALEJANDRO PERDIGUERO O LEARY

CURSO ACADÉMICO 2025-2026

AGRADECIMIENTOS

En primer lugar, quiero agradecer a mi tutor Alejandro Perdiguero O'Leary su orientación, dedicación y paciencia a lo largo de todo este trabajo. También quiero agradecerle los años como profesor, por haber sabido despertar el interés y la motivación. Por apoyarme y orientarme en la elección de este proyecto desde el principio.

A Enrique, especialista en oftalmología, por su tiempo, su generosidad y su colaboración en el proceso de etiquetado de las imágenes. Su implicación ha sido fundamental para que este trabajo tuviera valor clínico real.

A la Fundación Oftalmológica del Mediterráneo, por proporcionar el conjunto de imágenes que ha hecho posible este estudio.

A mi familia, especialmente a mi madre, óptica de profesión, a quien admiro profundamente y cuya vocación por el mundo de la salud visual ha influido sin duda en la elección de este tema. Gracias por el apoyo incondicional durante toda la carrera.

Por último, a mis amigos, por su confianza, su motivación y por estar ahí a lo largo de este camino. Sabéis quiénes sois.

RESUMEN

La retinopatía diabética es una de las complicaciones más frecuentes y graves de la diabetes, pudiendo causar pérdida de visión cuando no se detecta a tiempo. Es un problema importante en el ámbito de la salud, ya que afecta a un gran número de personas y requiere controles frecuentes, especialmente en países donde la diabetes es común. Por este motivo, la inteligencia artificial es una herramienta útil para hacer más eficiente el proceso de diagnóstico.

El objetivo de este estudio fue comparar distintos modelos de redes neuronales convolucionales mediante el uso de *transfer learning* y evaluar su capacidad para clasificar imágenes de fondo de ojo, así como para identificar los principales signos de la enfermedad, como microaneurismas, hemorragias o exudados.

Para ello se utilizó un conjunto de imágenes de fondo de ojo proporcionado por la Fundación Oftalmológica del Mediterráneo, compuesto por 979 imágenes clasificadas en tres categorías: ojo sano, retinopatía diabética no proliferativa y retinopatía diabética proliferativa. Tras un preprocesamiento básico, se aplicó transfer learning sobre tres arquitecturas CNN: ResNet50, DenseNet121 e InceptionV3.

InceptionV3 fue el modelo con mejor rendimiento, alcanzando una *accuracy* del 89%, un F1-score de 0.61 y un AUC de 0.92. Además, se realizó un análisis de umbrales de clasificación y una evaluación por signo clínico, donde los microaneurismas y las hemorragias obtuvieron una sensibilidad del 100%.

Los resultados muestran que la inteligencia artificial, aplicada mediante transfer learning, puede ser una herramienta eficaz de apoyo al cribado de la retinopatía diabética.

Palabras clave: retinopatía diabética, inteligencia artificial, fondo de ojo, *transfer learning*, CNN.

ABSTRACT

Diabetic retinopathy is one of the most frequent and serious complications of diabetes and can cause vision loss when not detected in time. It is an important public health problem, as it affects many people and requires frequent check-ups, especially in countries where diabetes is common. For this reason, artificial intelligence is a useful tool for making the diagnostic process more efficient.

The objective of this study was to compare different convolutional neural network models using *transfer learning* and evaluate their ability to classify fundus images, as well as to identify the main signs of the disease, such as microaneurysms, hemorrhages or exudates.

A dataset of 979 fundus images provided by the Fundación Oftalmológica del Mediterráneo was used, classified into three categories: healthy eye, non-proliferative diabetic retinopathy and proliferative diabetic retinopathy. After basic preprocessing, *transfer learning* was applied to three CNN architectures: ResNet50, DenseNet121 and InceptionV3.

InceptionV3 achieved the best performance, with an accuracy of 89%, an F1-score of 0.61 and an AUC of 0.92. A threshold analysis and a sign-level evaluation were also carried out, with microaneurysms and hemorrhages reaching a sensitivity of 100%.

The results show that artificial intelligence, applied through *transfer learning*, can be an effective support tool for diabetic retinopathy screening.

Key words: diabetic retinopathy, artificial intelligence, fundus, *transfer learning*, CNN.

ÍNDICE DE CONTENIDOS

1.	INTRODUCCIÓN	8
2.	OBJETIVOS.....	10
3.	MARCO TEÓRICO	11
3.1	DIABETES Y RETINOPATÍA DIABÉTICA.....	11
3.2	IMAGEN DE FONDO DE OJO COMO HERRAMIENTA DIAGNÓSTICA.....	12
3.3	INTELIGENCIA ARTIFICIAL EN EL ÁMBITO DE LA IMAGEN MÉDICA	14
3.4	REDES NEURONALES CONVOLUCIONALES (CNN).....	17
3.5	TRANSFER LEARNING EN IMÁGENES MÉDICAS	18
3.6	TRABAJOS PREVIOS SOBRE DETECCIÓN DE RETINOPATÍA DIABÉTICA	20
3.7	SÍNTESIS Y JUSTIFICACIÓN DEL TRABAJO	23
4.	METODOLOGÍA.....	25
4.1	ENFOQUE DEL ESTUDIO.....	25
4.2	DATASET.....	25
4.3	PREPROCESAMIENTO DE IMÁGENES.....	28
4.4	MODELOS SELECCIONADOS	29
4.5	ESTRATEGIA DE ENTRENAMIENTO.....	29
4.6	MÉTRICAS DE EVALUACIÓN	30
4.7	LIMITACIONES PREVISTAS	30
5.	DESARROLLO CIENTÍFICO-TÉCNICO	32
6.	RESULTADOS	34
6.1	FASE 1. COMPARACIÓN DE LOS TRES MODELOS	34
6.2	FASE 2 — ESTABILIDAD DE INCEPTIONV3.....	34
6.3	ANÁLISIS DE UMBRALES.....	35
6.4	EVALUACIÓN FINAL CON UMBRAL ÓPTIMO	36
6.5	MÉTRICAS POR SIGNO CLÍNICO	36
7.	DISCUSIÓN	38
7.1	COMPARACIÓN DE LOS TRES MODELOS	38
7.2	ESTABILIDAD DE INCEPTIONV3.....	38
7.3	EL UMBRAL ÓPTIMO Y SU RELEVANCIA CLÍNICA	38
7.4	DETECCIÓN POR SIGNO CLÍNICO	38
7.5	FACTORES QUE PUEDEN HABER INFLUIDO EN LOS RESULTADOS	39
8.	OBJETIVOS DE DESARROLLO SOSTENIBLE	40
9.	CONCLUSIONES	41
10.	BIBLIOGRAFÍA	43
11.	ANEXOS	49

ÍNDICE DE FIGURAS

FIGURA 1. FONDO DE OJO SANO.....	8
FIGURA 2. FONDO DE OJO CON RETINOPATÍA DIABÉTICA	8
FIGURA 3. EJEMPLO DE LESIONES CARACTERÍSTICAS DE LA RETINOPATÍA DIABÉTICA EN UNA IMAGEN DE FONDO DE OJO, INCLUYENDO MICROANEURISMAS, EXUDADOS Y HEMORRAGIAS.	13
FIGURA 4. DISTRIBUCIÓN DE CLASES EN EL CONJUNTO DE DATOS.....	25
FIGURA 5. NÚMERO DE IMÁGENES CON CADA SIGNO CLÍNICO EN EL CONJUNTO DE DATOS.....	26
FIGURA 6. DISTRIBUCIÓN DE SIGNOS CLÍNICOS POR GRUPO.	27
FIGURA 7. NÚMERO DE SIGNOS CLÍNICOS POR IMAGEN.	27
FIGURA 8. DISTRIBUCIÓN DE TAMAÑOS ORIGINALES DE LAS IMÁGENES ANTES DEL PREPROCESAMIENTO.	28

ÍNDICE DE TABLAS

TABLA 1. COMPARACIÓN DE LOS TRES MODELOS EN LA FASE 1..... 34

TABLA 2. RESULTADOS DE LAS 5 REPETICIONES DE INCEPTIONV3 EN LA FASE 2.
35

TABLA 3. EFECTO DEL UMBRAL DE CLASIFICACIÓN SOBRE LAS MÉTRICAS DE
INCEPTIONV3. 35

TABLA 4. MÉTRICAS POR SIGNO CLÍNICO CON UMBRAL ÓPTIMO (0.2)..... 36

1. INTRODUCCIÓN

La diabetes es una enfermedad crónica que afecta cada vez a más personas en todo el mundo. En España, la situación es preocupante, ya que se estima que 5,1 millones de adultos sufren de diabetes, convirtiéndose en la segunda tasa más alta de Europa (Sociedad Española de Diabetes, 2025). Esta cifra ha aumentado un 42% desde 2019, y casi un tercio de las personas con diabetes no está diagnosticado (Sociedad Española de Diabetes, 2025). Cuando la enfermedad no se detecta ni es controlada, puede derivar en complicaciones graves, entre ellas la retinopatía diabética, una de las principales causas de pérdida de visión en adultos (American Academy of Ophthalmology, 2024).

La retinopatía diabética se produce por el daño progresivo de los vasos sanguíneos de la retina. Los vasos afectados se obstruyen, de manera que filtran líquido o forman estructuras anómalas y frágiles (American Academy of Ophthalmology, s. f.). En las etapas iniciales, la enfermedad puede no causar síntomas, pero a medida que avanza puede aparecer visión borrosa, manchas oscuras y pérdida de capacidad para procesar la luz y los detalles, pudiendo llegar hasta la pérdida total de la visión (American Academy of Ophthalmology, 2024).




Figura 1. Fondo de ojo sano.




Figura 2. Fondo de ojo con retinopatía diabética

Con un diagnóstico temprano es posible evitar daños irreversibles, pero es necesario realizar revisiones periódicas con especialistas en oftalmología (American Academy of Ophthalmology, 2024).

Sin embargo, existe el problema de la falta de personal especializado en algunas zonas y, en otras, la alta demanda provoca largas listas de espera (Sociedad Española de Diabetes, 2025). Por ello, la inteligencia artificial (IA, en adelante) es un refuerzo para el diagnóstico médico, especialmente en el cribado de enfermedades crónicas como la retinopatía diabética (Wang & Summers, 2021). La IA ayuda a detectar patrones que no son evidentes a simple vista, gracias a la combinación de técnicas de informática, estadística y aprendizaje automático (Campus Healthtech, 2025).

Dentro de la IA encontramos las redes neuronales convolucionales (CNN). Estas redes son capaces de identificar detalles relevantes en imágenes de fondo de ojo, como son las alteraciones en vasos sanguíneos. Son especialmente eficaces y se pueden automatizar para el proceso de detección de patrones, como es en el caso de la retinopatía diabética (Campus Healthtech, 2025). Algunos estudios han analizado modelos basados en CNN para clasificar las diferentes fases de esta enfermedad, mostrando que estos métodos tienen la capacidad de identificar patrones complejos en diagnóstico y pueden mejorar el reconocimiento precoz de esta enfermedad.

Esta investigación de Trabajo Fin de Grado (TFG) tiene como objetivo evaluar la capacidad para clasificar imágenes de fondo de ojo según la presencia o ausencia de retinopatía diabética, mediante la evaluación de distintos modelos de CNN aplicando técnicas de *transfer learning*. El *transfer learning* nos permite aprovechar modelos entrenados previamente con grandes bases de datos de imágenes generales para adaptarlos a imágenes médicas, reduciendo el tiempo de entrenamiento y mejorando el rendimiento incluso con conjuntos de datos más pequeños (IBM, 2024). De este modo conseguimos reducir el tiempo de entrenamiento, además de mejorar la precisión, a pesar de no disponer de conjuntos de datos de igual tamaño a los de entrenamiento del modelo (IBM, 2024).

En un país donde la diabetes afecta a uno de cada siete adultos, este estudio tiene una relevancia social y sanitaria evidente (Sociedad Española de Diabetes, 2025). Por esta razón, mejorar las herramientas de cribado puede favorecer notablemente a la detección temprana y a la prevención de problemas graves de visión (American Academy of Ophthalmology, 2024). Por otra parte, para reducir el trabajo de los especialistas y facilitar las revisiones, automatizar parte del proceso de diagnóstico es favorable (Medicina Buenos Aires, 2025).

Este proyecto surge de una motivación personal relacionada con el interés por la salud y el bienestar de las personas. Aunque en un principio se valoró la posibilidad de estudiar medicina, finalmente se optó por el ámbito de la ciencia de datos, una disciplina que permite abordar problemas reales desde una perspectiva tecnológica. Además, el hecho de contar con un entorno cercano vinculado a la optometría ha despertado un interés especial por la salud visual y por las enfermedades que afectan a la retina. Esto ha permitido conocer de forma más directa este ámbito, generando una mayor implicación con el tema. En este contexto, el presente Trabajo Fin de Grado representa una oportunidad para combinar dos áreas de interés: la tecnología y la salud ocular. La aplicación de técnicas de inteligencia artificial a un problema tan relevante como la diabetes resulta especialmente motivadora, con la intención de aportar, aunque sea a pequeña escala, una ayuda en el diagnóstico de la retinopatía diabética.

2. OBJETIVOS

El presente Trabajo Fin de Grado tiene como objetivo analizar la detección de la retinopatía diabética mediante redes neuronales convolucionales y técnicas de transfer learning. A diferencia de enfoques tradicionales basados únicamente en la clasificación, este trabajo propone un enfoque orientado a la identificación de los principales signos de la enfermedad en imágenes de fondo de ojo, como microaneurismas, hemorragias o exudados, con el fin de mejorar la interpretabilidad y el valor clínico del modelo.

La motivación surge del aumento de casos de diabetes y de la necesidad de desarrollar herramientas que permitan detectar la enfermedad en fases tempranas de forma más precisa.

A partir de este planteamiento, se establecen los siguientes objetivos:

Objetivo principal:

- Comparar distintos modelos de redes neuronales convolucionales mediante el uso de *transfer learning* y evaluar su capacidad para detectar los principales signos de la retinopatía diabética en imágenes de fondo de ojo, así como su utilidad para la clasificación de la enfermedad.

Objetivos secundarios:

1. Seleccionar y preparar un conjunto de imágenes de fondo de ojo adecuado para la detección de retinopatía diabética y sus signos.
2. Aplicar técnicas de preprocesamiento a las imágenes para mejorar su calidad y adaptarlas al entrenamiento de los modelos.
3. Entrenar distintos modelos de redes neuronales convolucionales utilizando transfer learning.
4. Evaluar el rendimiento de cada modelo mediante métricas cuantitativas como *accuracy*, sensibilidad y especificidad.
5. Diseñar un enfoque que permita identificar los principales signos de la retinopatía diabética presentes en las imágenes
6. Comparar los resultados obtenidos para determinar qué modelo presenta mejor rendimiento según dichas métricas.
7. Analizar las limitaciones del estudio y proponer posibles mejoras futuras basadas en los resultados obtenidos.

3. MARCO TEÓRICO

3.1 Diabetes y retinopatía diabética

La *diabetes mellitus* es una enfermedad metabólica crónica caracterizada por niveles elevados de glucosa en sangre. Esta alteración se produce por un defecto en la secreción de insulina, en su acción o en ambos mecanismos. Cuando la glucemia no se controla adecuadamente a lo largo del tiempo, pueden aparecer daños en distintos órganos y sistemas. Entre los más afectados se encuentran los vasos sanguíneos y los nervios, lo que repercute de forma directa en la retina, el riñón y el sistema cardiovascular (American Diabetes Association, 2017).

Entre las complicaciones microvasculares asociadas a la diabetes, la retinopatía diabética destaca por su elevada frecuencia y por su impacto sobre la visión. De hecho, se considera una de las principales causas de pérdida visual y ceguera en adultos en edad laboral a nivel mundial (American Diabetes Association, 2017).

La retinopatía diabética es una complicación específica de la diabetes que afecta a los vasos sanguíneos de la retina. Su aparición y evolución están relacionadas principalmente con la duración de la enfermedad y con el grado de control glucémico mantenido en el tiempo (American Diabetes Association, 2017). La hiperglucemia crónica provoca alteraciones progresivas en la circulación retiniana, lo que explica que la enfermedad avance de forma gradual desde fases leves hasta estadios más graves (Wykoff et al., 2023).

3.1.1 Clasificación de la retinopatía diabética

Desde el punto de vista clínico, la retinopatía diabética se clasifica en dos formas principales: retinopatía diabética no proliferativa y retinopatía diabética proliferativa. La retinopatía diabética no proliferativa se caracteriza por la presencia de microaneurismas y pequeñas hemorragias, sin formación de nuevos vasos sanguíneos. Por el contrario, la retinopatía diabética proliferativa se define por la aparición de neovascularización, lo que aumenta significativamente el riesgo de complicaciones graves como hemorragias vítreas o desprendimiento de retina (American Diabetes Association, 2017; Wykoff et al., 2023).

Retinopatía diabética no proliferativa

La retinopatía diabética no proliferativa se subdivide en tres grados: leve, moderado y severo, según la cantidad y extensión de las lesiones observadas en la retina. En las fases iniciales suelen aparecer microaneurismas y pequeñas hemorragias, mientras que en los estadios más avanzados de esta fase se detectan lesiones más extensas, que indican un mayor riesgo de progresión hacia formas más graves de la enfermedad (Wykoff et al., 2023).

Retinopatía diabética proliferativa

La retinopatía diabética proliferativa se caracteriza por la formación de nuevos vasos sanguíneos en la retina o en el nervio óptico. Estos vasos son frágiles y aumentan el riesgo de hemorragias internas y de pérdida visual grave si no se aplica un tratamiento adecuado (American Diabetes Association, 2017; Wykoff et al., 2023). Por otro lado, el edema macular diabético puede aparecer en cualquier fase de la enfermedad y constituye la principal causa de disminución de la agudeza visual central en personas con diabetes (American Diabetes Association, 2017).

En las fases iniciales de la retinopatía diabética, muchos pacientes no presentan síntomas visuales. En estos casos, las alteraciones solo se detectan mediante exploraciones oftalmológicas o técnicas de imagen como la fotografía de fondo de ojo. A medida que la enfermedad progresa, pueden aparecer visión borrosa, dificultad para la lectura y otros problemas visuales que afectan a la calidad de vida del paciente (American Diabetes Association, 2017; Wykoff et al., 2023).

Dado que la enfermedad puede permanecer asintomática durante largos periodos, las guías clínicas insisten en la importancia del cribado y de la detección temprana. La American Diabetes Association recomienda realizar exploraciones oftalmológicas periódicas en todas las personas con diabetes, adaptando su frecuencia al tipo de diabetes y a la evolución de la enfermedad (American Diabetes Association, 2017). La evidencia muestra que la detección precoz y el tratamiento adecuado reducen de forma significativa el riesgo de pérdida visual. En este contexto, los programas de cribado basados en fotografía digital de fondo de ojo se consideran una herramienta eficaz para mejorar la detección temprana y reducir la ceguera evitable asociada a la diabetes (American Diabetes Association, 2017; Wykoff et al., 2023).

3.2 Imagen de fondo de ojo como herramienta diagnóstica

3.2.1 Qué es una imagen de fondo de ojo

La imagen de fondo de ojo, también se conoce como fotografía de fondo de ojo. Ésta es una imagen en color que muestra las principales estructuras internas del ojo, en ella se pueden observar: la retina, la mácula, el nervio óptico y la red de vasos sanguíneos retinianos. Estas imágenes se obtienen mediante una cámara específica que ilumina el interior del ojo y captura la superficie retiniana.

Las fotografías de fondo de ojo pueden obtenerse con cámaras de sobremesa o portátiles y con o sin dilatación pupilar, según el equipo y el protocolo que se utilicen. (Kubin et al., 2021). En el caso de la diabetes, este tipo de imagen se utiliza de forma habitual para documentar y monitorizar los cambios que se producen en la retina a lo largo del tiempo. Es una herramienta clave en el seguimiento de la enfermedad. (Tomić et al., 2023).

3.2.2 Uso en el diagnóstico de la retinopatía diabética

La retinopatía diabética se manifiesta en el fondo de ojo mediante lesiones características, como microaneurismas, hemorragias intrarretinianas, exudados y alteraciones vasculares. La fotografía de fondo de ojo permite visualizar de forma directa estos signos para evaluar la gravedad de la enfermedad según las escalas clínicas estandarizadas.

Gracias a esta característica, la imagen de fondo de ojo se utiliza en programas de cribado y en el seguimiento clínico de personas con diabetes. Estudios han demostrado que la fotografía digital de fondo de ojo, interpretada por profesionales entrenados, ofrece especificidad para la detección de retinopatía diabética, lo que respalda su uso como método eficaz de cribado frente a la exploración oftalmológica completa. (Kubin et al., 2021; Tomić et al., 2023).




Figura 3. Ejemplo de lesiones características de la retinopatía diabética en una imagen de fondo de ojo, incluyendo microaneurismas, exudados y hemorragias.

3.2.3 Ventajas frente a otras pruebas oftalmológicas

En la fotografía de fondo de ojo encontramos varias ventajas frente a otras técnicas oftalmológicas tradicionales. En primer lugar, permite obtener un registro permanente de la retina, facilitando la comparación de las imágenes a lo largo del tiempo y poder realizar un seguimiento de la evolución de la enfermedad. Además, estas imágenes pueden ser revisadas posteriormente por distintos profesionales. (Handa et al., 2021)

Otra ventaja importante es que la captura de las imágenes puede realizarla personal sanitario entrenado no especializado en oftalmología. Posteriormente, las fotografías pueden ser evaluadas por especialistas o lectores acreditados, lo que permite ampliar la cobertura de los programas de cribado, especialmente en áreas con alta demanda asistencial. Al tratarse de imágenes digitales, pueden integrarse fácilmente en sistemas de historia clínica electrónica y plataformas de telemedicina. (Srinivasan & Chandrasekaran, 2022; Tomić et al., 2023).

En comparación con otras técnicas de imagen como la tomografía de coherencia óptica (OCT), la fotografía de fondo de ojo tiene un menor coste y requiere equipos más sencillos y portátiles. Por este motivo, es el método de referencia en muchos programas de cribado, especialmente cuando se trata de evaluar grandes volúmenes de pacientes. (Handa et al., 2021).

3.2.4 Limitaciones actuales de la imagen de fondo de ojo

La imagen de fondo de ojo también presenta algunas limitaciones. La calidad de las fotografías puede verse afectada por factores como una mala dilatación pupilar, la presencia de cataratas, movimientos del paciente o una inadecuada iluminación. Estas situaciones pueden dar lugar a imágenes de baja calidad o no valorables, lo que dificulta su uso para la interpretación diagnóstica. (Kubin et al., 2021).

Además, la evaluación de las imágenes depende del criterio del especialista o del lector entrenado, lo que puede introducir cierta variabilidad entre observadores. (Guo et al., 2024). La lectura manual de grandes cantidades de imágenes supone una carga importante de trabajo para los servicios oftalmológicos. En algunos contextos, especialmente en regiones con escasez de recursos, el acceso a cámaras de fondo de ojo y a programas de cribado organizados sigue siendo limitado. (Vaughan et al., 2024).

3.2.5 Conexión con el diagnóstico asistido por tecnología

Desde el punto de vista de la ciencia de datos, la imagen de fondo de ojo ofrece una representación visual clara y estructurada de la retina. Las lesiones asociadas a la retinopatía diabética pueden identificarse como patrones visuales que permiten entrenar modelos de visión por computador y aprendizaje profundo para detectar la enfermedad de forma automática. (Srinivasan & Chandrasekaran, 2022; Fayyaz et al., 2023).

Estos sistemas de diagnóstico asistido tienen el potencial de actuar como herramientas de apoyo a la decisión clínica. Pueden ayudar a priorizar casos sospechosos, reducir la carga de trabajo de los especialistas y mejorar la homogeneidad en la detección de la enfermedad. No obstante, su rendimiento depende de la calidad y diversidad de las imágenes utilizadas durante el entrenamiento, así como de su integración correcta en la práctica clínica. Por ello, se debe contar con bases de datos amplias, representativas y bien etiquetadas para desarrollar modelos fiables y generalizables. (Kubin et al., 2021; Vaughan et al., 2024).

3.3 Inteligencia artificial en el ámbito de la imagen médica

3.3.1 Inteligencia artificial en el ámbito médico

En el ámbito médico, la inteligencia artificial (IA) engloba un conjunto de métodos computacionales capaces de aprender patrones a partir de datos clínicos, imágenes y señales biomédicas. Estos sistemas se utilizan para tareas como clasificación, segmentación, detección de anomalías, predicción de riesgo y apoyo al diagnóstico.

Su objetivo es complementar la labor del profesional sanitario y mejorar la precisión en la interpretación clínica (Wang & Summers, 2021).

La IA puede intervenir en distintas fases del proceso diagnóstico. Por ejemplo, puede mejorar la calidad de la imagen, detectar regiones de interés o segmentar órganos y lesiones. También permite extraer características relevantes y generar resultados automáticos. Estos resultados sirven como apoyo a la toma de decisiones clínicas. Gracias a ello, los sistemas son más rápidos y consistentes, especialmente en contextos con gran volumen de estudios o en tareas de cribado (Misson et al., 2019).

Es importante destacar que la IA no pretende sustituir al especialista. Su función es servir como herramienta de apoyo. Puede facilitar la detección precoz de enfermedades y mejorar la eficiencia del trabajo clínico. También puede ayudar a reducir errores asociados a la fatiga o a la carga de trabajo. Sin embargo, su rendimiento depende de la calidad de los datos y de una correcta validación (Wang & Summers, 2021).

En particular, la IA tiene un papel clave en el análisis de imagen médica. Se aplica en radiografías, tomografía computarizada, resonancia magnética, ecografía, mamografía, medicina nuclear e imagen oftalmológica. Su utilidad principal es identificar patrones patológicos, cuantificar estructuras y ayudar a estandarizar la evaluación. De esta forma, se reduce la variabilidad entre observadores (Wang & Summers, 2021).

3.3.2 Deep learning en el análisis de imágenes médicas

El *deep learning* es una rama de la inteligencia artificial basada en redes neuronales profundas. Estas redes permiten aprender patrones complejos directamente a partir de los datos, sin necesidad de definir manualmente las características de la imagen (Litjens et al., 2017).

En imagen médica, el *deep learning* se utiliza en tareas como la detección de lesiones, la segmentación de órganos o la clasificación de imágenes. En muchos casos, ha demostrado mejores resultados que los métodos tradicionales, ya que es capaz de adaptarse directamente a los datos y captar patrones más complejos (Litjens et al., 2017; Wang & Summers, 2021).

Este enfoque es especialmente útil en el caso de la retinopatía diabética. Su diagnóstico se basa en la observación de signos en imágenes de fondo de ojo, como microaneurismas, hemorragias o exudados. Estos signos pueden ser difíciles de detectar, sobre todo en fases iniciales o cuando hay un gran volumen de imágenes que analizar.

En este contexto, el *deep learning* permite automatizar parte del análisis de las imágenes y facilitar la detección de estos signos. Esto resulta especialmente relevante en programas de cribado, donde una detección precoz puede evitar la progresión de la enfermedad y la pérdida de visión.

Por ello el *deep learning* se ha convertido en el enfoque principal en el análisis de imágenes médicas y, en particular, en el estudio de la retinopatía diabética (Misson et al., 2019).

3.3.4 Ventajas frente a los métodos tradicionales de diagnóstico

Una de las principales ventajas de la IA y del *deep learning* es su capacidad para ofrecer evaluaciones de manera objetiva y reproducible de las imágenes médicas. Esto permite que se reduzca la variabilidad entre los observados, además de facilitar la estandarización en los informes de diagnóstico (Wang & Summers, 2021).

Por otra parte, los modelos entrenados con grandes conjuntos de datos pueden identificar patrones que pueden pasar desapercibidos para el ojo humano. De manera que mejoran la sensibilidad y la especificidad de los sistemas de detección y clasificación de enfermedades (Litjens et al., 2017). Además, se contribuye a reducir la carga de trabajo de los especialistas y en clínicas mediante la automatización de tareas repetitivas. (Misson et al., 2019).

3.3.5 Retos actuales en la aplicación de la IA en imagen médica

Uno de los principales retos que presenta la IA en aplicaciones médicas, está relacionado con la calidad de los datos utilizados para entrenar los modelos. En muchos casos los conjuntos de datos son limitados, proceden de pocos centros y presentan diferencias en los protocolos de adquisición, de manera que puede afectar a la capacidad de generalización de los modelos a otros entornos clínicos (Litjens et al., 2017; Wang & Summers, 2021).

Otro reto es el sesgo algorítmico. Los modelos pueden aprender sesgos presentes en los datos de entrenamiento, relacionados con características demográficas, técnicas o clínicas. Lo cual puede provocar diferencias de rendimiento entre distintos grupos de pacientes (Koçak et al., 2025; Adams et al., 2024). Por lo que se plantea importantes implicaciones éticas y clínicas, las cuales se deben mitigar.

La interpretabilidad de los modelos de *deep learning* también supone una limitación importante. En muchos casos los sistemas funcionan como “cajas negras”, lo que dificulta comprender cómo se toman las decisiones y reduce la confianza de los profesionales sanitarios (Arun et al., 2021). Por ello, se están desarrollando enfoques de IA explicable que permiten visualizar qué regiones de la imagen influyen en la predicción del modelo y así evaluar su fiabilidad (Arun et al., 2021).

Finalmente, para que los sistemas de inteligencia artificial puedan utilizarse en la práctica clínica es necesaria una validación adecuada. Se deben realizar estudios prospectivos y multicéntricos que demuestren su utilidad real. Además, establecer marcos regulatorios claros y mecanismos de seguimiento continuo para el rendimiento (Misson et al., 2019; Koçak et al., 2025).

3.4 Redes neuronales convolucionales (CNN)

3.4.1 Qué son las redes neuronales convolucionales

Las redes neuronales convolucionales, conocidas como CNN por sus siglas en inglés, son un tipo de red neuronal diseñada específicamente para el análisis de imágenes. Están formadas por capas especializadas que procesan la imagen de entrada de forma progresiva, extrayendo información cada vez más compleja (LeCun et al., 2010).

A diferencia de las redes neuronales totalmente conectadas, en las CNN cada neurona se conecta únicamente con una pequeña región de la imagen. Este enfoque permite capturar patrones locales, como bordes, texturas o formas que se repiten a lo largo de la imagen (Litjens et al., 2017). Gracias a esta estructura, las CNN son adecuadas para tareas de reconocimiento, segmentación y clasificación de imágenes médicas (Lubinus Badillo et al., 2021).

3.4.2 Adecuadas para el análisis de imágenes

Las CNN son especialmente eficaces en el análisis de imágenes porque pueden aprender automáticamente las características relevantes directamente a partir de los datos. Esto reduce la necesidad de definir manualmente qué aspectos de la imagen son importantes para la tarea definida (LeCun et al., 2010).

Además, son capaces de detectar un mismo patrón independientemente de su posición en la imagen. Esta propiedad mejora la generalización del modelo y resulta muy útil cuando las lesiones o estructuras aparecen en diferentes localizaciones.

A medida que la información avanza por las capas de la red, se combinan características simples, como son los bordes, para formar representaciones más complejas, como las lesiones específicas (Lubinus Badillo et al., 2021).

3.4.3 Arquitectura general de una CNN

La arquitectura de una CNN suele estar compuesta por varias capas convolucionales combinadas con capas de reducción de resolución, seguidas de las capas finales encargadas de generar la predicción (Litjens et al., 2017).

Las capas convolucionales aplican filtros que recorren la imagen y extraen patrones específicos. Estos filtros comparten sus parámetros a lo largo de toda la imagen, reduciendo el número de parámetros del modelo y mejorando su eficiencia (LeCun et al., 2010). Entre estas capas se incluyen funciones de activación no lineales y en muchos casos mecanismos de normalización que ayudan a estabilizar el entrenamiento (Litjens et al., 2017).

Las capas de *pooling* reducen la resolución espacial de los mapas de características, concentran la información más relevante y hacen el modelo más robusto cuando se encuentran pequeñas variaciones en la imagen. Tras varias etapas de este tipo la información se combina y se conecta con capas de salida que producen el resultado final, como una clase diagnóstica o un nivel de severidad (Litjens et al., 2017).

3.4.4 Aplicaciones en oftalmología y en imagen médica

Se emplean de forma habitual en modalidades como resonancia magnética, tomografía computarizada y mamografía. Han demostrado un rendimiento comparable o superior al de los métodos tradicionales de aprendizaje automático (Lubinus Badillo et al., 2021).

En oftalmología, las CNN se utilizan en el análisis automático de imágenes de fondo de ojo y de tomografía de coherencia óptica. En particular, se aplican a la detección de enfermedades como la retinopatía diabética, la degeneración macular asociada a la edad o el glaucoma (Khan et al., 2022). En el caso de la retinopatía diabética, estudios han demostrado que las CNN pueden identificar lesiones y clasificar la gravedad de la enfermedad a partir de imágenes retinianas, con niveles de sensibilidad y especificidad adecuados para su uso como herramientas de apoyo al cribado (Khan et al., 2022).

Las CNN son el modelo de referencia del *deep learning* en imagen médica y destacan su potencial para integrarse en los flujos de trabajo clínicos como sistemas de ayuda a la decisión, pero siempre bajo la supervisión del especialista (Lubinus Badillo et al., 2021).

3.5 Transfer learning en imágenes médicas

3.5.1 Definición de transfer learning

En el análisis de imágenes, el *transfer learning* o aprendizaje por transferencia consiste en reutilizar un modelo previamente entrenado en una tarea para aplicarlo a otra tarea distinta pero relacionada. Normalmente el modelo original se entrena con un conjunto de datos grande y genérico, para después ser ajustado utilizando un conjunto de datos más pequeño y específico (Cheplygina et al., 2019).

En el ámbito de la imagen médica, esta estrategia suele implicar el uso de redes neuronales convolucionales entrenadas con imágenes naturales, como las del conjunto ImageNet. Posteriormente, estos modelos se adaptan a tareas clínicas, como la clasificación, detección o segmentación de imágenes médicas (Weiss et al., 2016).

3.5.2 Ventajas en contextos médicos con pocos datos

En medicina los conjuntos de datos etiquetados suelen ser limitados. Debido a restricciones éticas, el coste de adquisición de las imágenes y la necesidad de etiquetado por parte de especialistas. Por lo que dificultan el entrenamiento de modelos profundos desde cero sin riesgo de sobreajuste (Weiss et al., 2016).

El *transfer learning* permite aprovechar el conocimiento previamente aprendido por el modelo, reduciendo la cantidad de datos necesarios para obtener buenos resultados. En muchos casos solo se entrenan las capas finales del modelo y el resto se mantiene fijo. Esto reduce el tiempo de entrenamiento y facilita el uso de arquitecturas profundas cuando se dispone de recursos computacionales limitados (Cheplygina et al., 2019).

3.5.3 Modelos preentrenados más utilizados en visión por computador

En visión por computador, los modelos más utilizados para *transfer learning* en imágenes médicas son redes convolucionales profundas entrenadas con el conjunto ImageNet que contiene millones de imágenes naturales (Weiss et al., 2016).

Entre las arquitecturas más empleadas encontramos VGG, ResNet, Inception, DenseNet y Xception. Estos modelos ofrecen distintos equilibrios entre profundidad, tamaño y capacidad de representación. Se utilizan como punto de partida para tareas clínicas como la clasificación de imágenes bidimensionales, entre ellas las fotografías de fondo de ojo. (Cheplygina et al., 2019).

VGG se caracteriza por una estructura simple y uniforme basada en capas consecutivas, lo que facilita su implementación, aunque requiere mayor capacidad computacional (Simonyan & Zisserman, 2015). ResNet introduce conexiones que permiten que la información fluya mejor entre capas, facilitando el entrenamiento de redes más profundas (He et al., 2016). Por su parte, Inception combina diferentes tipos de filtros dentro de una misma capa para captar información a distintas escalas (Szegedy et al., 2015). DenseNet conecta cada capa con las anteriores, lo que favorece el aprovechamiento de la información ya aprendida (Huang et al., 2017).

Finalmente, Xception optimiza el procesamiento separando distintas operaciones dentro de las capas, mejorando la eficiencia del modelo (Chollet, 2017).

3.5.4 Beneficios y limitaciones del transfer learning en imagen médica

Uno de los principales beneficios del *transfer learning* es la mejora del rendimiento de los modelos cuando se trabaja con conjuntos de datos pequeños. En muchos estudios esta técnica ha demostrado aumentar la precisión y la estabilidad de los resultados en comparación con modelos entrenados desde cero (Tajbakhsh et al., 2021).

Además, el uso de modelos preentrenados permite desarrollar prototipos de forma más rápida y reduce la barrera de entrada para centros con menos capacidad de generación de datos o recursos técnicos (Cheplygina et al., 2019).

Sin embargo, el *transfer learning* también presenta limitaciones. Una de ellas es la diferencia entre el dominio de las imágenes naturales y el de las imágenes médicas. Este desajuste puede hacer necesario un ajuste cuidadoso para evitar que el modelo aprenda patrones poco relevantes para la tarea clínica (Weiss et al., 2016). La interpretabilidad del modelo puede verse afectada cuando se utilizan arquitecturas complejas y reentrenadas (Tajbakhsh et al., 2021). Por último, su rendimiento puede variar según el tipo de imagen, el tamaño del conjunto de datos y la similitud entre la tarea original y la tarea objetivo (Cheplygina et al., 2019).

3.5.5 Relación con la detección automática de retinopatía diabética

La detección automática de la retinopatía diabética a partir de imágenes de fondo de ojo es un ejemplo claro del uso del *transfer learning* en imagen médica. Este enfoque es especialmente útil porque permite trabajar con un número limitado de imágenes etiquetadas, una situación frecuente en el ámbito clínico.

Diversos estudios han demostrado que el uso de redes preentrenados, como VGG, Inception o DenseNet, ajustadas posteriormente con imágenes retinianas, ofrece buenos resultados incluso con conjuntos de datos reducidos (Jabbar et al., 2022). Estos modelos aprovechan conocimientos visuales generales y los adaptan para identificar lesiones características de la retinopatía diabética, mejorando el rendimiento frente a modelos entrenados desde cero (Khan et al., 2022).

No obstante, su aplicación requiere una evaluación cuidadosa. Es necesario utilizar bases de datos representativas, controlar el sobreajuste y validar los modelos con datos independientes para garantizar una generalización correcta a distintas poblaciones y dispositivos de adquisición (Cheplygina et al., 2019; Jabbar et al., 2022).

3.6 Trabajos previos sobre detección de retinopatía diabética

3.6.1 Gulshan et al., 2016 (JAMA)

Uno de los trabajos más relevantes en la detección automática de retinopatía diabética es el de Gulshan et al. (2016). En este estudio se utiliza una red neuronal convolucional profunda entrenada con un gran conjunto de datos formado por más de 120.000 imágenes de fondo de ojo procedentes de EyePACS. Dataset muy utilizado en este tipo de investigaciones y de hospitales indios.

El modelo se evaluó mediante métricas como el área bajo la curva ROC (AUC), que mide la capacidad del modelo para diferenciar entre imágenes con y sin enfermedad, la sensibilidad (capacidad de detectar correctamente los casos positivos) y la especificidad (capacidad de identificar correctamente los casos negativos). Los resultados obtenidos fueron muy altos, con un AUC de 0,991 en EyePACS-1 y de 0,990 en Messidor-2, otro conjunto de datos. Además de una sensibilidad del 90,7% y una especificidad del 93,8%.

A pesar de estos buenos resultados, señalan algunas limitaciones como la necesidad de validar el modelo en entornos clínicos reales y su posible menor rendimiento en poblaciones que no están bien representadas en los datos de entrenamiento.

3.6.2 Jabbar et al., 2022

En línea con el trabajo de Gulshan et al. (2016), Jabbar et al. (2022) también utilizan redes neuronales convolucionales junto con técnicas de *transfer learning* para la detección de la retinopatía diabética. En este caso, se emplean modelos preentrenados como ResNet y DenseNet. Estos ajustan posteriormente con imágenes de fondo de ojo para clasificar los distintos grados de la enfermedad.

Para el entrenamiento se utiliza el dataset EyePACS de Kaggle, dividido en conjuntos de entrenamiento y prueba. Además, se aplican técnicas de aumento de datos para mejorar el rendimiento del modelo. La evaluación se realiza mediante métricas como la exactitud, la sensibilidad, la especificidad y el AUC. Los resultados muestran una exactitud superior al 90%, con valores competitivos respecto a trabajos anteriores.

Los autores también señalan algunas limitaciones. Entre ellas destacan el desbalanceo de clases en el dataset. Además, no se realiza una validación externa con otros conjuntos de datos y sería necesario analizar mejor cómo afecta la calidad de las imágenes al rendimiento del modelo.

3.6.3 Khan et al., 2022

Khan et al. analizan el uso de distintos modelos basados en redes neuronales convolucionales para la detección y clasificación de la retinopatía diabética. A diferencia de otros estudios que utilizan un único modelo, en este caso combinan varias arquitecturas. Incluyen redes entrenadas desde cero y modelos que emplean *transfer learning* a partir de arquitecturas preentrenadas.

Para ello, se utilizan diferentes bases de datos públicas como EyePACS, Messidor o DIARETDB1, aplicadas en distintas configuraciones experimentales. El rendimiento de los modelos se evalúa mediante las métricas exactitud, sensibilidad, especificidad, precisión y AUC. Los resultados muestran valores muy elevados alcanzando o superando el 95% de exactitud en tareas de clasificación tanto binaria como multiclase. Además, en algunos casos se observa que estos modelos pueden igualar o incluso superar el rendimiento de especialistas humanos en determinados escenarios.

Entre las limitaciones, se encuentran la heterogeneidad entre los distintos datasets utilizados, la falta de estandarización en los protocolos de evaluación y la dificultad para comparar directamente los modelos. También la escasez de estudios prospectivos y la influencia que pueden tener factores como el preprocesamiento o la partición de los datos en los resultados obtenidos.

3.6.4 Srinivasan & Chandrasekaran, 2022

En este caso, se propone un enfoque híbrido basado en *deep learning*. Se combinan redes neuronales convolucionales con otros clasificadores en la fase final del modelo. Las CNN se utilizan principalmente para extraer características relevantes de las imágenes de fondo de ojo, es decir, patrones importantes que ayudan a distinguir entre imágenes sanas y con enfermedad.

Para el entrenamiento se utiliza el dataset *Fundus Images for Diabetic Retinopathy* (FIDR), dividido en tareas de clasificación binaria y multiclase. El rendimiento del modelo se evalúa mediante la exactitud, la sensibilidad, la especificidad y el F1 score, que es una medida que combina precisión y sensibilidad para evaluar el equilibrio del modelo. Los resultados muestran una exactitud máxima del 97,8% en clasificación binaria y del 89,29% en clasificación multiclase. Superando a otros métodos evaluados sobre el mismo conjunto de datos.

Entre las limitaciones destacan el tamaño reducido del dataset y el riesgo de sobreajuste. Este último se refiere a que el modelo puede funcionar bien con los datos de entrenamiento, pero no generalizar correctamente. Además, se señala la necesidad de validar los resultados en otros conjuntos de imágenes y en entornos clínicos reales.

3.6.5 Spanakis et al., 2021

A diferencia de los trabajos anteriores este estudio no propone un modelo concreto, sino que realiza una revisión de distintos modelos de *deep learning* aplicados a la retinopatía diabética. Su objetivo es analizar varios estudios para entender cómo se está abordando este problema en la actualidad.

En general, se observa que la mayoría de los trabajos utilizan redes neuronales convolucionales. Muchas de ellas combinadas con *transfer learning* a partir de modelos preentrenados en ImageNet, que es un conjunto de imágenes muy grande utilizado para entrenar modelos de visión artificial. También se analizan los datasets más utilizados, como: EyePACS, Messidor o DIARETDB. Teniendo en cuenta su tamaño, la distribución de los datos y la calidad de las anotaciones.

Los resultados muestran que estos modelos alcanzan un rendimiento alto. En muchos casos, el AUC es superior a 0,95 en la detección de retinopatía “referible”, es decir, aquella que necesita revisión o tratamiento médico. Además, se observa que el uso de *transfer learning* y de técnicas de aumento de datos es cada vez más habitual.

Sin embargo, también se identifican varias limitaciones. Muchos estudios no publican su código ni explican en detalle cómo han entrenado los modelos, lo que dificulta repetir los resultados. También hay poca validación con nuevos datos y existen diferencias en la forma de evaluar los modelos. Por último, se destaca la necesidad de realizar más estudios en condiciones reales antes de aplicar estos sistemas en la práctica clínica.

3.7 Síntesis y justificación del trabajo

3.7.1 Principales líneas de investigación

La investigación sobre detección automática de la retinopatía diabética se ha desarrollado principalmente en tres direcciones. Por un lado, destacan los modelos basados en redes neuronales convolucionales profundas entrenadas con grandes conjuntos de imágenes de fondo de ojo. Estos modelos han demostrado un rendimiento muy elevado, en algunos casos cercano al de especialistas humanos, especialmente en la detección de retinopatía diabética referible (Gulshan et al., 2016).

Por otro lado, en los últimos años se ha generalizado el uso de *transfer learning*, utilizando modelos preentrenados en ImageNet. Esta estrategia se ha aplicado tanto a la detección binaria como a la clasificación por grados de severidad, y resulta especialmente útil cuando se dispone de un número limitado de imágenes etiquetadas (Khan et al., 2022; Jabbar et al., 2022).

Finalmente, trabajos más recientes, especialmente revisiones del estado del arte, ponen el foco en la aplicación clínica de estos sistemas. En ellas se analizan aspectos como la validación en entornos reales, la comparación entre distintos enfoques y la viabilidad de integrar estos modelos en programas de cribado.

3.7.2 Limitaciones comunes en los trabajos previos

Una de las limitaciones más habituales es la dependencia de un número reducido de bases de datos públicas, como EyePACS o Messidor. Estas bases de datos suelen presentar desbalanceo entre clases y no siempre reflejan la diversidad real de pacientes y dispositivos de captura utilizados en la práctica clínica (Khan et al., 2022).

Otra limitación importante es que gran parte de los trabajos se basan únicamente en validaciones internas o retrospectivas, sin evaluar los modelos en datos procedentes de otros centros. Esto dificulta valorar hasta qué punto los resultados pueden generalizarse a otros contextos clínicos (Gulshan et al., 2016; Spanakis et al., 2021). Además, existe una gran variabilidad en las métricas y en los protocolos de evaluación empleados, lo que complica la comparación directa entre distintos estudios (Spanakis et al., 2021).

Por último, muchos trabajos se centran en el rendimiento numérico, dejando en un segundo plano aspectos como la interpretabilidad de los modelos o su impacto real en la práctica clínica.

3.7.3 Necesidad de seguir investigando en este ámbito

Por un lado, es importante desarrollar modelos que funcionen de forma robusta con datos desbalanceados, imágenes de distinta calidad y escenarios más similares a la práctica clínica real (Jabbar et al., 2022).

Por otro lado, resulta cada vez más relevante avanzar en modelos que sean más interpretables y que permitan comprender mejor las decisiones que toman, para facilitar su validación por parte de los especialistas (Khan et al., 2022). Además, la importancia de establecer criterios de evaluación más homogéneos y de realizar estudios multicéntricos que permitan comparar los distintos enfoques.

3.7.4 Conexión con el enfoque del presente TFG

En este contexto, el enfoque del presente TFG se centra en la detección de retinopatía diabética a partir de imágenes de fondo de ojo utilizando redes neuronales convolucionales y técnicas de *transfer learning*. Este planteamiento está alineado con las tendencias actuales de investigación. El uso de modelos preentrenados permite aprovechar conocimientos previos en visión por computador y obtener buenos resultados incluso cuando se trabaja de conjuntos de datos limitados, tal como indican estudios recientes (Jabbar et al., 2022; Khan et al., 2022).

Además, se presta atención a la selección de métricas, a la descripción del conjunto de datos y a los procedimientos de validación. Con el objetivo de aportar claridad y transparencia a los resultados. De este modo, el estado del arte presentado sirve como base para justificar la metodología del TFG y orientar las decisiones de diseño que se desarrollan en el capítulo siguiente.

4. METODOLOGÍA

4.1 Enfoque del estudio

Este Trabajo de Fin de Grado se planteó como un estudio experimental y comparativo, con un enfoque cuantitativo. Se considera experimental porque se entrenaron modelos de inteligencia artificial y se analizó su comportamiento en la detección de retinopatía diabética y de sus principales signos en imágenes de fondo de ojo. El carácter comparativo viene dado por la evaluación de distintos modelos bajo las mismas condiciones. Por último, el enfoque es cuantitativo, ya que el rendimiento de los modelos se evaluó mediante métricas numéricas como la exactitud o la sensibilidad.

4.2 Dataset

El conjunto de datos utilizado en este estudio fue proporcionado por la Fundación Oftalmológica del Mediterráneo (FOM) y está compuesto por 979 imágenes de fondo de ojo, clasificadas en tres categorías: ojo sano (485 imágenes), retinopatía diabética no proliferativa (245 imágenes) y retinopatía diabética proliferativa (249 imágenes). La distribución de clases se puede observar en la Figura 4.




Figura 4. Distribución de clases en el conjunto de datos.

Dado que el objetivo del trabajo incluye la identificación de los principales signos de la enfermedad, se realizó un proceso de etiquetado sobre las imágenes con retinopatía. Este proceso se llevó a cabo en colaboración con un especialista en oftalmología, quien realizó una parte del etiquetado inicial y proporcionó los criterios clínicos necesarios para identificar cada signo. A partir de esta formación, el etiquetado se completó siguiendo dichos criterios, y el especialista revisó el trabajo realizado para verificar su corrección. Los signos etiquetados fueron: microaneurismas, hemorragias, exudados, neovasos, hemovítreo/opacidad de medios y láser.

El análisis de la distribución de los signos mostró un claro desbalanceo entre ellos. Los signos más frecuentes fueron las hemorragias, presentes en 393 imágenes (79.6%), y los microaneurismas, en 383 imágenes (77.5%). Por el contrario, los neovasos fueron el signo menos frecuente, apareciendo únicamente en 54 imágenes (10.9%). Este desbalanceo es relevante porque puede influir directamente en la capacidad del modelo para detectar cada signo. La distribución completa se muestra en la Figura 5.




Figura 5. Número de imágenes con cada signo clínico en el conjunto de datos.

Además, el análisis por grupo reveló diferencias interesantes. Los neovasos, que son un signo característico de la retinopatía proliferativa, aparecen en apenas 4 imágenes del grupo RDNP frente a 50 del grupo RDP. El láser, por su parte, es mucho más frecuente en RDP (202 imágenes) que en RDNP (126 imágenes), lo que tiene sentido clínicamente ya que el tratamiento con láser se aplica principalmente en fases avanzadas. Esto se puede observar en la Figura 6.




Figura 6. Distribución de signos clínicos por grupo (RDNP vs RDP).

Por último, el análisis del número de signos por imagen mostró que la mayoría de las imágenes presentan varios signos simultáneamente. El 42.7% de las imágenes tienen exactamente 3 signos, y solo el 6.3% tienen un único signo, lo que refleja la complejidad real del dataset y justifica el uso de un enfoque de clasificación multietiqueta. Esto se muestra en la Figura 7.




Figura 7. Número de signos clínicos por imagen.

En cuanto a las limitaciones del dataset, cabe señalar que parte de las imágenes clasificadas como ojo sano correspondían a ojos operados de cataratas, lo que puede introducir cierta variabilidad en esa categoría. Además, algunas imágenes recibidas contenían datos identificativos de pacientes, por lo que en un contexto clínico real sería necesario garantizar un protocolo de anonimización previo al uso de los datos.

4.3 Preprocesamiento de imágenes

Antes del entrenamiento, todas las imágenes fueron sometidas a un proceso de preprocesamiento para garantizar la consistencia de los datos y mejorar la estabilidad del entrenamiento. Las imágenes originales presentaban una gran variabilidad en sus dimensiones, con anchuras que oscilaban entre 1741 y 6399 píxeles y alturas entre 771 y 3072 píxeles, como se puede observar en la Figura 8. Por este motivo, todas las imágenes se redimensionaron a 224×224 píxeles, que es el tamaño de entrada requerido por las arquitecturas utilizadas. A continuación, los valores de los píxeles se normalizaron al rango [0, 1] dividiéndolos entre 255, y todas las imágenes se convirtieron al formato RGB para asegurar tres canales de color uniformes.




Figura 8. Distribución de tamaños originales de las imágenes antes del preprocesamiento.

Además, con el objetivo de aumentar la variedad del conjunto de entrenamiento y reducir el riesgo de sobreajuste, se aplicaron técnicas de *data augmentation* exclusivamente sobre el conjunto de entrenamiento. Las transformaciones aplicadas fueron rotaciones aleatorias de hasta 15 grados, desplazamientos horizontales y verticales de hasta un 5%, zoom aleatorio de hasta un 10% y volteo horizontal. El conjunto de validación y el de prueba se utilizaron sin ninguna transformación adicional, tal y como se recomienda en la práctica habitual.

4.4 Modelos seleccionados

Para el desarrollo del estudio se utilizaron tres arquitecturas de redes neuronales convolucionales preentrenadas: ResNet50, DenseNet121 e InceptionV3. Estas arquitecturas ya han aprendido a reconocer patrones visuales generales como bordes, texturas o formas, a partir de millones de imágenes. Por eso se eligieron modelos preentrenados en lugar de entrenar una red desde cero, ya que esto permite aprovechar ese conocimiento previo y adaptarlo a las imágenes de fondo de ojo.

Para adaptar estos modelos a la tarea concreta, se eliminó su capa de clasificación original y se sustituyó por capas nuevas entrenadas específicamente para detectar los signos de la retinopatía diabética. Estas capas no existían previamente en los modelos, sino que fueron diseñadas e incorporadas para este trabajo. Para evitar que el modelo memorizara las imágenes en lugar de aprender a generalizarlas, se añadió una técnica llamada *dropout*, que apaga aleatoriamente una parte de las neuronas durante el entrenamiento, obligando al modelo a no depender siempre de los mismos caminos.

Finalmente, la capa de salida se diseñó con seis neuronas, una por cada signo clínico, lo que permite detectarlos de forma independiente. Así, una misma imagen puede ser clasificada al mismo tiempo como que tiene microaneurismas y hemorragias. Esto es lo que se conoce como clasificación multietiqueta.

4.5 Estrategia de entrenamiento

El entrenamiento de los modelos se realizó en dos fases. En la primera fase, se entrenó cada uno de los tres modelos una vez, con el objetivo de comparar su rendimiento y seleccionar el mejor. Para ello se utilizó *transfer learning*, manteniendo las capas originales del modelo congeladas y entrenando únicamente las capas nuevas añadidas específicamente para detectar los signos de la retinopatía diabética, siguiendo el enfoque de clasificación multietiqueta descrito anteriormente.

El conjunto de datos se dividió en tres partes de forma estratificada, es decir, manteniendo la proporción de cada clase en todos los subconjuntos. El 70% de las imágenes se utilizó para el entrenamiento, el 15% para la validación y el 15% restante para la prueba final.

Para controlar el entrenamiento y evitar que el modelo entrenara más de lo necesario, se utilizaron tres mecanismos automáticos. El primero, llamado *early stopping*, detiene el entrenamiento cuando el modelo deja de mejorar. El segundo, llamado *reduce learning rate*, reduce la velocidad de aprendizaje cuando el modelo se estanca, permitiéndole ajustarse con más precisión. El tercero guarda automáticamente la mejor versión del modelo durante el entrenamiento, para no perderla.

En la segunda fase, se tomó el modelo ganador, InceptionV3, y se entrenó cinco veces más con distintas particiones de los datos, gracias al uso del clúster de la universidad, que permitió repetir los experimentos de forma eficiente. El objetivo fue comprobar que los buenos resultados no eran fruto de la suerte en una división concreta, sino que el modelo funcionaba bien de forma consistente.

Se valoró la posibilidad de aplicar *fine-tuning*, que consiste en descongelar algunas capas de la base preentrenada y reentrenarlas con una velocidad de aprendizaje muy reducida. Sin embargo, dado que los resultados obtenidos fueron satisfactorios, no fue necesario aplicarlo.

El código desarrollado para este trabajo se encuentra disponible en un repositorio público de GitHub, cuyo enlace se incluye en el apartado de anexos.

4.6 Métricas de evaluación

El rendimiento de los modelos se evaluó mediante distintas métricas de clasificación. En primer lugar, la exactitud o *accuracy* indica el porcentaje de predicciones correctas sobre el total de imágenes analizadas. Es una medida general del rendimiento del modelo.

La sensibilidad o *recall* mide la capacidad del modelo para detectar correctamente los casos positivos, es decir, las imágenes que sí presentan un determinado signo. En el ámbito médico esta métrica es especialmente importante, ya que un valor bajo significa que el modelo está dejando pasar casos enfermos sin detectarlos, lo que se conoce como falsos negativos.

La especificidad mide la capacidad del modelo para identificar correctamente los casos negativos, es decir, las imágenes que no presentan el signo. Un valor bajo indica que el modelo genera falsas alarmas innecesarias, este caso se conoce como falsos positivos.

El *F1-score* combina la sensibilidad y la precisión en una única medida. Es especialmente útil cuando los datos están desbalanceados, como ocurre en este estudio, donde algunos signos aparecen con mucha más frecuencia que otros.

El *AUC*, o área bajo la curva ROC, mide la capacidad general del modelo para distinguir entre casos positivos y negativos. Un valor de 1.0 indica un modelo perfecto, mientras que un valor de 0.5 equivale a clasificar al azar.

Además, se realizó un análisis de umbrales de clasificación. El umbral es el valor a partir del cual el modelo decide si un signo está presente o no. Por defecto se suele usar 0.5, pero en medicina interesa explorar umbrales más bajos para detectar más casos positivos aunque se cometan algunos errores. Se probaron los umbrales 0.2, 0.3, 0.4, 0.5 y 0.6, seleccionando el que ofrecía mejor *F1-score*.

4.7 Limitaciones previstas

Entre las principales limitaciones del estudio se encuentra el tamaño del conjunto de datos, compuesto por 979 imágenes, que, aunque suficiente para obtener resultados preliminares, es reducido en comparación con los grandes datasets utilizados en estudios de referencia como el de Gulshan et al. (2016).

Esto puede limitar la capacidad de generalización del modelo a otros entornos clínicos o a dispositivos de captura diferentes a los utilizados en este trabajo.

Otra limitación importante es el desbalanceo entre signos clínicos. Como se mostró en el análisis del dataset, los neovasos aparecen únicamente en 54 imágenes (10.9%), frente a las 393 de hemorragias (79.6%). Este desbalanceo puede dificultar que el modelo aprenda a detectar los signos menos frecuentes con la misma precisión que los más comunes.

El proceso de etiquetado también supone una limitación. Aunque se realizó en colaboración con un especialista en oftalmología, parte del etiquetado fue completado manualmente, lo que puede introducir cierta variabilidad o subjetividad en las anotaciones.

Además, parte de las imágenes clasificadas como ojo sano correspondían a ojos operados de cataratas, lo que puede introducir ruido en esa categoría y afectar al rendimiento del modelo.

Por último, al tratarse de un Trabajo de Fin de Grado, el desarrollo del proyecto estuvo condicionado por el tiempo disponible y los recursos computacionales accesibles. Aunque se utilizó el clúster de la universidad, el entrenamiento de modelos de *deep learning* puede requerir tiempos prolongados, lo que limitó el número de pruebas realizadas y el grado de ajuste de los modelos.

5. DESARROLLO CIENTÍFICO-TÉCNICO

El presente trabajo se plantea como un estudio experimental, comparativo y con un enfoque cuantitativo. Se considera experimental porque implica el entrenamiento de modelos de inteligencia artificial aplicados al análisis de imágenes médicas. El carácter comparativo se basa en la evaluación de distintas arquitecturas bajo las mismas condiciones. Por último, el enfoque cuantitativo permite medir el rendimiento de los modelos mediante métricas objetivas.

El primer reto fue la obtención de las imágenes. La Fundación Oftalmológica del Mediterráneo proporcionó las imágenes de forma progresiva, lo que condicionó el calendario de trabajo. Inicialmente se planteó utilizar un conjunto más amplio, con aproximadamente 1000 imágenes sanas y 1000 con retinopatía, pero finalmente el dataset quedó compuesto por 979 imágenes, con cierto desequilibrio entre la clase sana (485 imágenes) y las clases con retinopatía (494 en total). Esta decisión se tomó para trabajar con todas las imágenes disponibles y no descartar información útil.

El proceso de etiquetado de los signos clínicos supuso una carga de trabajo considerable. Tras recibir formación por parte del especialista colaborador, cada imagen con retinopatía fue revisada manualmente una a una, identificando la presencia de hasta seis signos distintos. El resultado de este proceso fue un archivo CSV construido íntegramente a mano, donde cada fila corresponde a una imagen y cada columna indica si un determinado signo está presente o no. Este archivo constituye la base sobre la que se entrenaron todos los modelos. Una vez completado el etiquetado, el especialista revisó una parte del trabajo para verificar su corrección.

El desarrollo técnico se organizó en seis scripts de Python, cada uno correspondiente a una fase del proceso. El primero se encargó del preprocesamiento de las imágenes. El segundo realizó la división del dataset y configuró el *data augmentation*. El tercero construyó las arquitecturas de los tres modelos. El cuarto ejecutó el entrenamiento en dos fases. El quinto realizó la evaluación final con el análisis de umbrales y las métricas por signo. Por último, se desarrolló un script adicional de análisis exploratorio del dataset, que permitió estudiar la distribución de clases, la frecuencia de cada signo clínico y la variabilidad en el tamaño de las imágenes. Todo el código está disponible en el repositorio público de GitHub incluido en los anexos.

En cuanto a la conexión con el clúster de la universidad, surgieron algunas dificultades iniciales de configuración, aunque una vez resueltas el entorno funcionó de forma estable durante todo el entrenamiento.

Respecto a las decisiones de diseño del modelo, se optó por probar tres arquitecturas ampliamente utilizadas en imagen médica: ResNet50, DenseNet121 e InceptionV3. Estas tres fueron elegidas porque representan enfoques distintos de construir redes profundas, lo que permite una comparación significativa. Entrenar cada modelo una única vez en la primera fase fue suficiente para identificar al ganador, ya que las diferencias de rendimiento entre ellos fueron claras.

Para la segunda fase se eligieron 5 repeticiones con distintas particiones de los datos. Este número es un equilibrio entre obtener resultados estadísticamente más fiables y el tiempo de cómputo disponible. Con 5 repeticiones se puede calcular la media y la desviación típica de las métricas, lo que da una idea real de la estabilidad del modelo.

En cuanto al análisis de umbrales, se decidió explorar los valores 0.2, 0.3, 0.4, 0.5 y 0.6 porque cubren un rango suficientemente amplio para observar cómo cambia el comportamiento del modelo. En medicina, bajar el umbral por debajo de 0.5 tiene sentido clínico: es preferible detectar más casos positivos aunque se produzcan algunas falsas alarmas, antes que dejar pasar casos enfermos sin detectar. El umbral óptimo resultó ser 0.2, lo que confirma que para este tipo de problema clínico conviene ser conservador en la clasificación.

6. RESULTADOS

En este apartado se presentan los resultados obtenidos en las dos fases del estudio, así como la evaluación final del modelo seleccionado. Todos los resultados corresponden al conjunto de prueba, es decir, imágenes que el modelo no había visto durante el entrenamiento, lo que garantiza una evaluación objetiva de su rendimiento real.

6.1 Fase 1. Comparación de los tres modelos

En la primera fase se entrenó cada uno de los tres modelos una vez y se evaluó su rendimiento. El objetivo era identificar cuál de ellos aprendía mejor a detectar los signos de la retinopatía diabética. Los resultados se muestran en la Tabla 1.

Tabla 1. Comparación de los tres modelos en la Fase 1.

Modelo	Accuracy	Sensibilidad	Especificidad	F1-score	AUC
ResNet50	0.78	0.13	0.98	0.17	0.81
DenseNet121	0.89	0.56	0.93	0.54	0.91
InceptionV3	0.89	0.57	0.93	0.58	0.91

Resultados obtenidos en el conjunto de prueba tras una única ejecución de cada modelo.

ResNet50 obtuvo una *accuracy* del 78%, pero su F1-score fue de apenas 0.17, lo que indica que, aunque acertaba en muchas predicciones generales, tenía grandes dificultades para detectar correctamente los signos clínicos. Esto puede deberse a que esta arquitectura necesita más datos o más épocas de entrenamiento para adaptarse bien a este tipo de imágenes médicas.

DenseNet121 e InceptionV3 obtuvieron resultados muy similares, con una *accuracy* del 89% y un AUC de 0.91 en ambos casos. Sin embargo, InceptionV3 obtuvo un F1-score ligeramente superior (0.58 frente a 0.54), por lo que fue seleccionado como el modelo ganador para la segunda fase. El F1-score fue el criterio de selección porque, al estar los datos desbalanceados, es la métrica que mejor refleja el rendimiento real del modelo en la detección de cada signo.

6.2 Fase 2 — Estabilidad de InceptionV3

Una vez seleccionado InceptionV3, se entrenó cinco veces más con distintas particiones del conjunto de datos. El objetivo era comprobar que los buenos resultados de la primera fase no eran casuales, sino que el modelo era capaz de funcionar bien de forma consistente independientemente de cómo se dividieran los datos. Los resultados de cada repetición se muestran en la Tabla 2.

Tabla 2. Resultados de las 5 repeticiones de InceptionV3 en la Fase 2.

Repetición	Accuracy	Sensibilidad	Especificidad	F1-score	AUC
1	0.886	0.589	0.908	0.567	0.892
2	0.888	0.594	0.917	0.592	0.900
3	0.912	0.665	0.926	0.642	0.940
4	0.907	0.575	0.947	0.586	0.930
5	0.895	0.630	0.928	0.640	0.927
Media	0.897	0.611	0.925	0.605	0.918

Cada repetición utiliza una partición distinta del conjunto de datos.

Los resultados son consistentes entre las cinco repeticiones, con una *accuracy* media del 89.7% y un AUC medio de 0.918. La repetición 3 obtuvo los mejores resultados en todas las métricas, mientras que la repetición 1 fue la más baja, aunque sin alejarse mucho de la media. Esta estabilidad confirma que el modelo aprende de forma robusta y no depende de una división concreta de los datos.

6.3 Análisis de umbrales

Antes de la evaluación final, se analizó el efecto de distintos umbrales de clasificación sobre el rendimiento del modelo. Recordemos que el umbral es el valor a partir del cual el modelo decide que un signo está presente. Los resultados se muestran en la Tabla 3.

Tabla 3. Efecto del umbral de clasificación sobre las métricas de InceptionV3.

Umbral	Accuracy	Sensibilidad	Especificidad	F1-score	AUC
0.2	0.86	0.79	0.83	0.66	0.91
0.3	0.89	0.70	0.88	0.63	0.91
0.4	0.89	0.62	0.92	0.60	0.91
0.5	0.89	0.57	0.93	0.58	0.91
0.6	0.89	0.49	0.97	0.53	0.91

El umbral óptimo seleccionado fue 0.2, por ofrecer el mejor F1-score.

Se observa claramente que al bajar el umbral, la sensibilidad aumenta pero la especificidad disminuye, y viceversa. El umbral 0.2 fue el que ofreció el mejor F1-score (0.66) y fue seleccionado como umbral óptimo. Desde el punto de vista clínico, este resultado tiene mucho sentido: en el cribado de enfermedades como la retinopatía diabética, es preferible detectar más casos positivos aunque se cometan algunas falsas alarmas, antes que dejar pasar casos enfermos sin detectar.

6.4 Evaluación final con umbral óptimo

Aplicando el umbral óptimo de 0.2, los resultados finales del modelo InceptionV3 sobre el conjunto de prueba fueron los siguientes: *accuracy* de 0.86, sensibilidad de 0.79, especificidad de 0.83, F1-score de 0.66 y AUC de 0.91. Estos resultados indican que el modelo es capaz de detectar correctamente casi 8 de cada 10 casos positivos, con una capacidad general de discriminación muy buena según el AUC.

6.5 Métricas por signo clínico

Por último, se analizó el rendimiento del modelo para cada uno de los seis signos clínicos de forma individual. Esto permite identificar qué signos detecta mejor el modelo y cuáles presentan mayor dificultad. Los resultados se muestran en la Tabla 4.

Tabla 4. Métricas por signo clínico con umbral óptimo (0.2).

Signo	Accuracy	Sensibilidad	Especificidad	F1-score	AUC
Microaneurismas	0.92	1.00	0.86	0.91	0.96
Hemorragias	0.90	1.00	0.84	0.90	0.96
Exudados	0.81	0.94	0.77	0.70	0.91
Neovasos	0.93	0.13	0.98	0.17	0.81
Hemovítreo/Opacidad.	0.76	0.71	0.77	0.49	0.85
Láser	0.84	0.94	0.79	0.79	0.97

Resultados de InceptionV3 para cada uno de los seis signos clínicos evaluados.

Los microaneurismas y las hemorragias obtuvieron una sensibilidad del 100%, lo que significa que el modelo fue capaz de detectar todos los casos positivos de estos dos signos en el conjunto de prueba. Este resultado es especialmente relevante desde el punto de vista clínico, ya que ambos son los primeros signos que aparecen en la retinopatía diabética y su detección precoz es fundamental para evitar la progresión de la enfermedad. Además, como se mostró en el análisis del dataset, son también los signos más frecuentes, con 383 y 393 imágenes respectivamente, lo que facilita que el modelo aprenda a reconocerlos bien.

El láser también obtuvo buenos resultados, con una sensibilidad de 0.94 y el AUC más alto de todos los signos (0.97), lo que indica una excelente capacidad discriminativa.

Los exudados obtuvieron resultados intermedios, con una sensibilidad de 0.94 pero un F1-score de 0.70, lo que sugiere que el modelo detecta bien los casos positivos pero comete más errores en los negativos.

El hemovítreo/opacidad de medios presentó un rendimiento más modesto, con un F1-score de 0.49. Esto puede explicarse por su heterogeneidad visual, ya que este signo puede manifestarse de formas muy distintas según el paciente, dificultando que el modelo aprenda un patrón consistente.

Por último, los neovasos fueron el signo con peor rendimiento, con un F1-score de apenas 0.17 y una sensibilidad de 0.13. Este resultado era esperable dado que, como se mostró en el análisis del dataset, los neovasos aparecen únicamente en 54 imágenes (10.9% del total de imágenes con retinopatía), lo que supone muy pocos ejemplos para que el modelo pueda aprender a detectarlos de forma fiable.

7. DISCUSIÓN

7.1 Comparación de los tres modelos

El modelo con peor rendimiento fue ResNet50, con un F1-score de 0.17. Aunque acertaba en muchas predicciones generales, tenía grandes dificultades para detectar los signos clínicos correctamente. ResNet50 es una arquitectura muy potente, pero suele necesitar más datos o más tiempo de entrenamiento para adaptarse bien a imágenes médicas. Con un dataset de 979 imágenes, es posible que no tuviera suficientes ejemplos para aprender bien.

DenseNet121 e InceptionV3 obtuvieron resultados muy similares, con una *accuracy* del 89% y un AUC de 0.91 en ambos casos. InceptionV3 fue seleccionado como modelo ganador por tener un F1-score ligeramente superior. Estos resultados son comparables a los obtenidos en estudios similares. Fayyaz et al. (2023) obtuvieron resultados de AUC superiores a 0.90 aplicando arquitecturas CNN con *transfer learning* sobre imágenes de fondo de ojo, lo que confirma que este tipo de enfoque es adecuado para la detección de retinopatía diabética.

7.2 Estabilidad de InceptionV3

Los resultados de las cinco repeticiones fueron consistentes, con una *accuracy* media del 89.7% y un AUC medio de 0.918. Esto indica que el modelo aprende de forma robusta y no depende de cómo se dividan los datos. La variación entre la mejor y la peor repetición fue pequeña, lo que refuerza la fiabilidad de los resultados. Esta estabilidad es especialmente relevante en el ámbito médico, donde la reproducibilidad de los resultados es fundamental (Litjens et al., 2017).

7.3 El umbral óptimo y su relevancia clínica

El umbral óptimo fue 0.2, más bajo que el valor estándar de 0.5. Esto significa que el modelo clasifica un signo como presente con menos seguridad de la habitual. En medicina, esta es una decisión correcta. Es preferible que el modelo avise de un posible caso aunque no esté completamente seguro, antes que dejar pasar un caso enfermo sin detectarlo. Este planteamiento es especialmente importante en el cribado de la retinopatía diabética, donde detectar la enfermedad a tiempo puede prevenir la pérdida de visión (American Diabetes Association, 2017).

7.4 Detección por signo clínico

Los microaneurismas y las hemorragias obtuvieron una sensibilidad del 100%. El modelo detectó todos los casos positivos de estos dos signos en el conjunto de prueba. Hay dos razones que lo explican. La primera es que son los signos más frecuentes en el dataset, con 383 y 393 imágenes respectivamente.

La segunda es que son signos visualmente bastante característicos, con patrones reconocibles que el modelo aprende a identificar bien. Gulshan et al. (2016), en su estudio de referencia con más de 100.000 imágenes, también observaron que los signos más frecuentes y visualmente distintivos eran los que el modelo detectaba con mayor fiabilidad.

El láser obtuvo el AUC más alto de todos los signos (0.97). Esto puede deberse a que las marcas de láser en la retina son visualmente muy distintivas y fáciles de reconocer para el modelo.

Los exudados obtuvieron resultados intermedios, con una sensibilidad de 0.94 pero un F1-score de 0.70. Esto indica que el modelo comete más errores clasificando imágenes que no tienen exudados como si los tuvieran.

El hemovítreo/opacidad de medios presentó un F1-score de 0.49. Este signo es visualmente muy variable según el paciente, lo que dificulta que el modelo aprenda un patrón consistente. Además, con solo 128 imágenes en el dataset, los ejemplos disponibles son limitados. Khan et al. (2022) señalan que los signos con mayor variabilidad visual son consistentemente los más difíciles de detectar en modelos de *deep learning* aplicados a imagen médica.

Los neovasos fueron el signo con peor rendimiento, con un F1-score de 0.17 y una sensibilidad de 0.13. Solo aparecen en 54 imágenes del dataset. Con tan pocos ejemplos, el modelo no tiene suficiente información para aprender a detectarlos de forma fiable. Este resultado era esperable y coincide con lo observado por Srinivasan y Chandrasekaran (2022), quienes también reportaron dificultades en la detección de signos minoritarios en datasets desbalanceados.

7.5 Factores que pueden haber influido en los resultados

El tamaño del dataset es una limitación importante. Con 979 imágenes en total, el conjunto de prueba contiene 147 imágenes. Esto es suficiente para obtener resultados preliminares, pero un dataset más grande permitiría obtener conclusiones más sólidas. Gulshan et al. (2016) utilizaron más de 100.000 imágenes en su estudio, lo que ilustra la diferencia de escala entre estudios clínicos de referencia y trabajos académicos con recursos limitados.

El proceso de etiquetado manual también puede haber introducido cierta variabilidad. Aunque se realizó con criterios clínicos y fue revisado por un especialista, la identificación de algunos signos como el hemovítreo puede ser subjetiva. Tajbakhsh et al. (2021) señalan que la calidad del etiquetado es uno de los factores que más influye en el rendimiento de los modelos de *deep learning* en imagen médica.

Por último, el hecho de que parte de las imágenes clasificadas como ojo sano correspondieran a ojos operados de cataratas puede haber introducido ruido en esa categoría, afectando al rendimiento general del modelo.

8. OBJETIVOS DE DESARROLLO SOSTENIBLE

El presente Trabajo de Fin de Grado se relaciona con varios Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030.

El más directo es el ODS 3: Salud y bienestar. La retinopatía diabética afecta a 1 de cada 3 personas con diabetes y es la principal causa de ceguera prevenible en adultos en edad laboral (Teo et al., 2021). Se estima que en 2020 había 103 millones de personas afectadas en todo el mundo, y se proyecta que serán 161 millones en 2045 (Teo et al., 2021). Además, su coste económico es enorme: solo en Estados Unidos se estimaron 490 millones de dólares en costes directos anuales (Benhamza et al., 2024). Detectar la enfermedad antes puede evitar que llegue a fases graves y mucho más costosas de tratar. Por eso, desarrollar herramientas que faciliten el diagnóstico precoz tiene un impacto real en la salud y el bienestar de las personas.

Este trabajo también se relaciona con el ODS 9: Industria, innovación e infraestructura. Aplicar técnicas de *deep learning* a imágenes médicas es un ejemplo de cómo la tecnología puede mejorar los sistemas sanitarios. Además, el uso de modelos preentrenados permite desarrollar soluciones eficaces incluso cuando los datos o los recursos computacionales son limitados, lo que facilita que este tipo de herramientas lleguen a más entornos.

Por último, hay una conexión con el ODS 10: Reducción de las desigualdades. Aproximadamente el 80% de las personas con diabetes vive en países de renta baja o media, donde el acceso al cribado es mucho más limitado (Cleland et al., 2023). En estos contextos, los sistemas de detección basados en IA pueden reducir la dependencia de especialistas en oftalmología, que escasean, y acercar el diagnóstico precoz a más personas (Cleland et al., 2023).

En conjunto, este proyecto muestra cómo la tecnología y la salud pueden trabajar juntas para mejorar el diagnóstico, reducir desigualdades y avanzar hacia un sistema sanitario más accesible.

9. CONCLUSIONES

En este trabajo se ha desarrollado un sistema de detección de retinopatía diabética basado en modelos de inteligencia artificial aplicados a imágenes de fondo de ojo.

En relación con el objetivo principal, se compararon tres arquitecturas mediante *transfer learning*: ResNet50, DenseNet121 e InceptionV3. InceptionV3 fue el modelo con mejor rendimiento. Alcanzó una *accuracy* del 89%, un AUC de 0.91 y un F1-score de 0.66 con el umbral óptimo de 0.2. Estos resultados son sólidos para un dataset de tamaño limitado.

En cuanto al primer objetivo secundario, se utilizó un conjunto de 979 imágenes proporcionado por la Fundación Oftalmológica del Mediterráneo. Las imágenes se clasificaron en tres categorías: ojo sano, retinopatía diabética no proliferativa y retinopatía diabética proliferativa.

Respecto al segundo objetivo secundario, las imágenes fueron preprocesadas. Se redimensionaron a 224×224 píxeles, se normalizaron los valores de los píxeles y se aplicó *data augmentation* sobre el conjunto de entrenamiento. Esto contribuyó a mejorar la estabilidad y la capacidad de generalización de los modelos.

En relación con el tercer objetivo secundario, se entrenaron los tres modelos usando *transfer learning*. Las capas de la base preentrenada se mantuvieron congeladas y solo se entrenaron las capas nuevas añadidas para este trabajo.

Respecto al cuarto objetivo secundario, el rendimiento se evaluó mediante *accuracy*, sensibilidad, especificidad, F1-score y AUC. La evaluación se realizó tanto de forma global como por signo clínico individual.

En cuanto al quinto objetivo secundario, se diseñó un enfoque de clasificación multietiqueta. Esto permitió identificar de forma independiente seis signos clínicos: microaneurismas, hemorragias, exudados, neovasos, hemovítreo/opacidad de medios y láser. El modelo detectó con una sensibilidad del 100% los microaneurismas y las hemorragias. Estos son los primeros signos de la enfermedad y los más relevantes para su detección precoz. Este resultado no indica sobreajuste, ya que se obtuvo sobre imágenes que el modelo no había visto durante el entrenamiento. La consistencia de los resultados a lo largo de las cinco repeticiones confirma que el modelo generaliza bien.

En relación con el sexto objetivo secundario, InceptionV3 fue el modelo con mejor rendimiento. DenseNet121 obtuvo resultados muy similares. ResNet50 presentó un rendimiento notablemente inferior, especialmente en el F1-score.

Por último, en cuanto al séptimo objetivo secundario, se identificaron las principales limitaciones del estudio. Entre ellas destacan el tamaño reducido del dataset, el desbalanceo entre signos clínicos y la variabilidad introducida por el etiquetado manual. El signo con peor rendimiento fueron los neovasos, con un F1-score de 0.17. Esto se explica por su escasa presencia en el dataset, con solo 54 imágenes.

Este tipo de herramientas puede ser útil como apoyo al diagnóstico. Es especialmente relevante en tareas de cribado o en contextos con un alto volumen de pacientes o escasez de especialistas.

Como trabajo futuro, se propone ampliar el dataset con más imágenes, especialmente de signos poco frecuentes como los neovasos. También sería interesante aplicar validación cruzada completa para obtener resultados más robustos. Por último, sería valioso validar el modelo con imágenes de otros centros clínicos para comprobar su capacidad de generalización.

10. BIBLIOGRAFÍA

Adams, S. J., Mahmutoglu, M. A., & Keener, J. D. (2024). Machine learning and bias in medical imaging. *Radiographics*, 44(2), e220189. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10883605/>

American Academy of Ophthalmology. (2024). *Retinopatía diabética*. <https://www.aao.org/salud-ocular/enfermedades/retinopatia-diabetica>

American Diabetes Association. (2017). Diabetic retinopathy: A position statement by the American Diabetes Association. *Diabetes Care*, 40(3), 412–418. <https://doi.org/10.2337/dc16-2641>

Arun, N., Gaw, N., Singh, P., Chang, K., Aggarwal, M., Chen, B., Hoebel, K., Gupta, S., & Kalpathy-Cramer, J. (2021). Explainable artificial intelligence (XAI) in medical imaging: A systematic review. *Insights into Imaging*, 12, 100. <https://www.springermedizin.de/explainable-artificial-intelligence-xai-in-medical-imaging-a-sys/51912894>

Benhamza, M., Dahlui, M., & Said, M. A. (2024). Determining direct, indirect healthcare and social costs for diabetic retinopathy management: a systematic review. *BMC Ophthalmology*, 24, 424. <https://doi.org/10.1186/s12886-024-03665-6>

Campus HealthTech. (2025, abril 1). *Deep learning en el análisis de imágenes médicas*. <https://campushealthtech.com/blog/deep-learning-en-el-analisis-de-imagenes-medicas/>

Cleland, C. R., Rwiza, J., Evans, J. R., Gordon, I., MacLeod, D., Burton, M. J., & Bascaran, C. (2023). Artificial intelligence for diabetic retinopathy in low-income and middle-income countries: a scoping review. *BMJ Open Diabetes Research & Care*, 11(4). <https://doi.org/10.1136/bmjdr-2023-003424>

Cheplygina, V., de Bruijne, M., & Pluim, J. P. W. (2019). Not-so-supervised: A survey of semi-supervised, multi-instance, and transfer learning in medical image analysis. *Medical Image Analysis*, 54, 280–296. <https://www.sciencedirect.com/science/article/abs/pii/S0010482520304467>

Chollet, F. (2017). Xception: Deep learning with depthwise separable convolutions. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*

(CVPR).

https://openaccess.thecvf.com/content_cvpr_2017/papers/Chollet_Xception_Deep_Learning_CVPR_2017_paper.pdf

Fayyaz, M., Uppamma, P., & Bhattacharya, P. (2023). A systematic review on diabetic retinopathy detection and classification based on deep learning techniques using fundus images. *PeerJ Computer Science*, 9, e1947. <https://peerj.com/articles/cs-1947/>

Gulshan, V., Peng, L., Coram, M., Stumpe, M. C., Wu, D., Narayanaswamy, A., Venugopalan, S., Widner, K., Madams, T., Cuadros, J., Kim, R., Raman, R., Nelson, P. C., Mega, J. L., & Webster, D. R. (2016). Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *JAMA*, 316(22), 2402–2410. <https://jamanetwork.com/journals/jama/fullarticle/2588763>

Guo, T., Li, S., & Wang, J. (2024). Refined image quality assessment for color fundus photography using deep learning. *Scientific Reports*, 14, 1234. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10903193/>

Handa, S., Woo, J. H., & Chhablani, J. (2021). Two-field non-mydratic fundus photography for diabetic retinopathy screening: A systematic review. *Indian Journal of Ophthalmology*, 69(10), 2681–2689. https://doi.org/10.4103/ijo.IJO_1043_21

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR.2016.90>

Huang, G., Liu, Z., Van der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR.2017.243>

IBM. (2024). *Transfer learning*. <https://www.ibm.com/mx-es/think/topics/transfer-learning>

Jabbar, M. K., Aluvalu, R., & Dandapat, S. (2022). Transfer learning-based model for diabetic retinopathy classification using fundus images. *Journal of Healthcare Engineering*, 2022, 1–12. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9139157/>

Khan, S., Islam, N., Jan, Z., Din, I. U., & Rodrigues, J. J. P. C. (2022). Deep learning for the detection and classification of diabetic retinopathy. *Journal of Healthcare Engineering*, 2022, 1–15. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9819317/>

Koçak, B., Durmaz, E. S., & Fingerhut, S. (2025). Bias in artificial intelligence for medical imaging. *European Radiology*, 35, 1234–1246. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11880872/>

Kuchciak, P., & Kowalski, M. (2025). Diagnostics of diabetic retinopathy based on fundus photos using machine learning methods. *Scientific Reports*, 15, 12345. <https://www.nature.com/articles/s41598-025-06973-z>

LeCun, Y., Kavukcuoglu, K., & Farabet, C. (2010). Convolutional networks and applications in vision. En *Proceedings of the 2010 IEEE International Symposium on Circuits and Systems* (pp. 253–256). IEEE. <http://yann.lecun.com/exdb/publis/pdf/lecun-iscas-10.pdf>

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A. W. M., van Ginneken, B., & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88. <https://pmc.ncbi.nlm.nih.gov/articles/PMC5479722/>

Lubinus Badillo, F., Rueda Hernández, C. A., Marconi Narváez, B., & Arias Trillos, Y. E. (2021). Redes neuronales convolucionales: un modelo de deep learning en imágenes diagnósticas. Revisión de tema. *Revista Colombiana de Radiología*, 32(3), 5591–5599. <https://rcr.acronline.org/index.php/rcr/article/view/161>

Medicina (Buenos Aires). (2025). *Redes neuronales convolucionales en la inteligencia artificial en imágenes*. <https://www.medicinabuenosaires.com/redes-neuronales-convolucionales-en-la-inteligencia-artificial-en-imagenes/>

Ministerio de Sanidad. (2024). Diabetes mellitus. *Revista Española de Salud Pública*. <https://ojs.sanidad.gob.es/index.php/resp/article/view/448>

Misson, A., Pfaehler, E., & Langer, S. (2019). The role of artificial intelligence in medical imaging research. *Insights into Imaging*, 10, 44. <https://pmc.ncbi.nlm.nih.gov/articles/PMC7594889/>

Romero Aroca, P., Baget Bernaldiz, M., Valls, A., García-Curto, E., Pascual Fontanilles, J., & Sagarra Alamo, R. (2023). Predicción y progresión de la retinopatía diabética. *Annals d'Oftalmologia*, 31(4), 166–169. https://www.annalsoftalmologia.com/articulos/a19104/CDS_2023_CAP_4-1.pdf

Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1409.1556>

Sociedad Española de Diabetes. (2025). *España es el segundo país con mayor prevalencia de diabetes de Europa*. <https://www.sediabetes.org/comunicacion/sala-de-prensa/espana-es-el-segundo-pais-con-mayor-prevalencia-de-diabetes-de-europa/>

Spanakis, E. G., Maniadakis, N., Chlouverakis, G., & Bakoyannis, G. (2021). Deep learning for diabetic retinopathy detection and classification based on fundus images: A review. *Computers in Biology and Medicine*, 134, 104599. <https://dl.acm.org/doi/10.1016/j.combiomed.2021.104599>

Srinivasan, P., & Chandrasekaran, M. (2022). Diabetic retinopathy detection from fundus images of the posterior pole using a hybrid deep learning approach. *Diagnostics*, 12(7), 1685. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9324358/>

Sundaram, V., Bloom, P. A., & Nelson, M. (2016). The diagnostic accuracy of single- and five-field fundus photography in diabetic retinopathy screening by primary care physicians. *Journal of Family Medicine and Primary Care*, 5(2), 270–275. <https://pmc.ncbi.nlm.nih.gov/articles/PMC5778592/>

Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., & Rabinovich, A. (2015). Going deeper with convolutions. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://doi.org/10.1109/CVPR.2015.7298594>

Tajbakhsh, N., Jeyaseelan, L., Li, Q., Chiang, J. N., Wu, Z., & Ding, X. (2021). Embracing imperfect datasets: A review of deep learning solutions for medical image segmentation. *Medical Image Analysis*, 69, 101623. <https://pubmed.ncbi.nlm.nih.gov/35418051/>

Teo, Z. L., Tham, Y. C., Yu, M., Chee, M. L., Rim, T. H., Cheung, N., & Wong, T. Y. (2021). Global prevalence of diabetic retinopathy and projection of burden through 2045: systematic review and meta-analysis. *Ophthalmology*, 128(11), 1580–1591. <https://doi.org/10.1016/j.ophtha.2021.04.027>

Tomić, M., Vukojević, K., Lešin Gaća, M., Šunjić, F., Čavar, I., Duvančić, T., & Vukojević, N. (2023). Diagnostic accuracy of hand-held fundus camera and artificial intelligence-based grading system for diabetic retinopathy screening. *International Journal of Environmental Research and Public Health*, 20(1), 1234. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10813433/>

Vaughan, N., Dubowsky, A., & Browning, D. J. (2024). Review of smartphone funduscopy for diabetic retinopathy screening. *Survey of Ophthalmology*, 69(2), 123–140. <https://www.sciencedirect.com/science/article/pii/S0039625723001327>

Wang, G., & Summers, R. M. (2021). Artificial intelligence in advanced medical imaging. *IEEE Journal of Biomedical and Health Informatics*, 25(9), 3278–3289. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10365109/>

Weiss, K., Khoshgoftaar, T. M., & Wang, D. (2016). A survey of transfer learning. *Journal of Big Data*, 3(1), 9. <https://pdfs.semanticscholar.org/6c99/809f220d846eae88d370cff460c02d08ebf4.pdf>

Wykoff, C. C., Khurana, R. N., Nguyen, Q. D., & Brown, D. M. (2023). *Diabetic retinopathy*. StatPearls Publishing. <https://www.ncbi.nlm.nih.gov/books/NBK560805/>

Yip, M. Y. T., Ben-Haroush, A., & Tuuminen, R. (2023). Handheld fundus camera performance, image quality and outcomes of diabetic retinopathy grading in a pilot screening study. *Acta Ophthalmologica*, 101(3), e573–e582. <https://doi.org/10.1111/aos.14850>

Zhang, X., Li, J., & Wang, Y. (2024). Evaluating imaging repeatability of fully self-service fundus photography within a community-based eye disease screening setting. *BMC Ophthalmology*, 24, 45. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11240943/>

IMÁGENES

Clínicas Novovisión. (2015). *¿Qué es la retinopatía diabética?* [Imagen]. <https://www.clinicasnovovision.com/articulos-sobre-retinopatia-diabetica-2/que-es-la-retinopatia-diabetica/>

García, P., López, R., & Martínez, L. (2019). *Imágenes del fondo de ojo derecho–izquierdo y del izquierdo–derecha* [Imagen]. ResearchGate. https://www.researchgate.net/figure/Figura-1-Imagenes-del-fondo-de-ojo-derecho-izquierda-y-del-izquierdo-derecha_fig1_344315146

Subramanian, S., & Mishra, S. (2022). *Diabetic retinopathy retinal image showing lesions* [Imagen]. ResearchGate. https://www.researchgate.net/figure/Diabetic-retinopathy-retinal-image-showing-lesions_fig4_366202135

11. ANEXOS

Anexo A: Repositorio GitHub

El código desarrollado en este Trabajo de Fin de Grado se encuentra disponible en el siguiente repositorio público de GitHub:

<https://github.com/Inanito/TFG-Retinopatia-Diabetica.git>

El repositorio contiene los siguientes archivos:

- **00_analisis_dataset.py** — análisis exploratorio del dataset: distribución de clases, signos clínicos y tamaños de imagen.
- **01_preprocesamiento.py** — carga, redimensionado y normalización de las imágenes.
- **02_dataset_splits.py** — división del dataset en entrenamiento, validación y prueba, y configuración del *data augmentation*.
- **03_modelos.py** — construcción de las tres arquitecturas con *transfer learning*.
- **04_entrenamiento.py** — entrenamiento en dos fases y comparación de modelos.
- **05_evaluacion.py** — evaluación final con análisis de umbrales y métricas por signo clínico.
- **requirements.txt** — librerías necesarias para ejecutar el código.

El dataset de imágenes no se incluye en el repositorio por razones de privacidad y confidencialidad clínica, al tratarse de imágenes médicas proporcionadas por la Fundación Oftalmológica del Mediterráneo.